

Modelamiento y Optimización

Clase 21

Gonzalo Muñoz

6 de Junio 2024



Optimización No-Lineal



Optimización no-lineal

Ahora estudiaremos problemas del tipo

$$\begin{array}{ll} \text{mín} & f(x) \\ \text{sujeto a:} & g_i(x) \leq 0 \quad i = 1, \dots, m \\ & h_j(x) = 0 \quad j = 1, \dots, p \\ & x \in \mathbb{R}^n \end{array} \quad \leadsto \text{Sin variables enteras}$$

Donde $f, g_i : \mathbb{R}^n \rightarrow \mathbb{R}$ son funciones generales, y $h_j : \mathbb{R}^n \rightarrow \mathbb{R}$ son funciones lineales afín (más adelante veremos por qué conviene hacer esta distinción).

$$h_j(x) = a_j^T x + b_j \quad \} \text{función lineal afín}$$


Ejemplo

Encontrar el punto $x \in \mathbb{R}^2$ más cercano a $(3, 4)$ que esté a una distancia menor que 2 del punto $(0, 2)$ y $x_2 \in (-\infty, 2]$

$$\begin{array}{ll} \text{mín} & (x_1 - 3)^2 + (x_2 - 4)^2 \\ \text{sujeto a:} & x_2 \leq 2 \\ & x_1^2 + (x_2 - 2)^2 \leq 4 \end{array}$$




$$\|(x_1, x_2) - (0, 2)\| \leq 2$$



Diferencias principales con optimización lineal

En general, la optimización no-lineal es mucho más compleja y tenemos menos garantías. Por ejemplo, un óptimo podría no estar en un punto extremo:


$$\begin{array}{ll} \min & x_1^2 + x_2^2 \\ \text{s.a} & x_1 \leq 1 \\ & x_1 \geq -1 \\ & x_2 \leq 1 \\ & x_2 \geq -1 \end{array}$$



Incluso, un óptimo podría no alcanzarse:

$$\begin{array}{ll} \min & f(x) = \frac{1}{x} \\ \text{s.a} & x \geq 1 \end{array}$$

en realidad es un ínfimo.



Definiciones para optimización lineal

Necesitaremos las siguientes definiciones:

x es solución factible si

$$x \in S := \{z \in \mathbb{R}^n : g_i(z) \leq 0, i = 1, \dots, m, h_j(z) = 0, j = 1, \dots, p\}$$

x es un **óptimo global** si $x \in S$ y

$$f(x) \leq f(y) \quad \forall y \in S$$

} podría no existir

Ej: $B(x, \epsilon)$ bola pequeña abierta

x es un **óptimo local** si $x \in S$ y existe una vecindad N de x tal que

$$f(x) \leq f(y) \quad \forall y \in N \cap S$$

y también podrá no existir



Definiciones para optimización no-lineal


Las funciones convexas nos servirán para dar algunas **garantías** en los problemas de optimización.

Definición

Una función $f : \mathbb{R}^n \rightarrow \mathbb{R}$ se dice **convexa** si,

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y) \quad \forall x, y \in \mathbb{R}^n, \forall \lambda \in [0, 1]$$

Gráficamente:



Funciones convexas


Dos caracterizaciones usuales de convexidad:

Teorema

Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función

1. Si f es diferenciable, entonces es convexa si y solo si,

$$f(x) \geq f(y) + (x - y)^\top \nabla f(y) \quad \forall x, y \in \mathbb{R}^n$$



2. Si f es 2 veces diferenciable, entonces es convexa si y solo si,

$$\nabla^2 f(x) \text{ es semi-definida positiva } \forall x \in \mathbb{R}^n$$

$\nabla^2 f(x)$
Hessiano



Conjuntos convexos

Recordemos los **conjuntos convexos**, definidos cuando vimos PL

Definición

Decimos que un conjunto $C \subseteq \mathbb{R}^n$ es **convexo** si,

$$\lambda x + (1 - \lambda)y \in C \quad \forall x, y \in C, \forall \lambda \in [0, 1]$$

Ejemplos: Ya vimos que los **poliedros** son conjuntos convexos. Un ejemplo no-lineal son las **bolas** $B(\bar{x}, r) = \{x \in \mathbb{R}^n : \|x - \bar{x}\| \leq r\}$.

tomamos $x, y \in B(\bar{x}, r)$, $\lambda \in [0, 1]$

$$\begin{aligned} \|\lambda x + (1-\lambda)y - \bar{x}\| &= \|\underbrace{\lambda x}_{\text{m}} + \underbrace{(1-\lambda)y}_{\text{m}} - \underbrace{\lambda \bar{x}}_{\text{m}} - \underbrace{(1-\lambda)\bar{x}}_{\text{m}}\| \\ &\stackrel{\text{des. triangular}}{\leq} \|\lambda x - \lambda \bar{x}\| + \|(1-\lambda)y - (1-\lambda)\bar{x}\| \\ &\stackrel{\substack{\lambda \geq 0 \\ 1-\lambda \geq 0}}{=} \lambda \underbrace{\|x - \bar{x}\|}_{\leq r} + (1-\lambda) \underbrace{\|y - \bar{x}\|}_{\leq r} \\ &\leq r \quad \checkmark \end{aligned}$$

Región factible convexa

En general, si las funciones $g_i(x)$ son convexas, el **conjunto**

$$S = \{x \in \mathbb{R}^n : g_i(x) \leq 0, i = 1, \dots, m, h_j(x) = 0, j = 1, \dots, p\}$$

es convexo.

lineales afín. son
concavas y convexas
 $-h_j$ es convexa

Sea $x, y \in S, \lambda \in [0, 1]$

$$g_i(\lambda x + (1-\lambda)y) \stackrel{g_i \text{ convexa}}{\leq} \underbrace{\lambda g_i(x)}_{\leq 0} + \underbrace{(1-\lambda) g_i(y)}_{\leq 0} \leq 0$$

$$\begin{aligned} h_j(\lambda x + (1-\lambda)y) &= a_j^T (\lambda x + (1-\lambda)y) + \overbrace{b_j}^{\lambda b_j + (1-\lambda)b_j} \\ &= \lambda (\underbrace{a_j^T x + b_j}_{=0}) + (1-\lambda) (\underbrace{a_j^T y + b_j}_{=0}) \\ &= 0 \end{aligned}$$

Nota: $g_i(x) = 0$ con g_i convexa, puede no ser
conjunto convexo $E_j = \{x : \|x\| = 1\}$

Condiciones de optimalidad general

Teorema (Weierstrass)

Si $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es continua, y la región factible S es cerrada y acotada (compacta), entonces $\min_{x \in S} f(x)$ tiene un óptimo global.

Cuando f, g_i son funciones convexas y h_j son funciones lineales afín, el conjunto factible es convexo y el problema se llama **problema convexo**.

Teorema

Supongamos que el problema es convexo. Entonces **un óptimo local es un óptimo global**.



Ejemplo

Determinar si el siguiente ejemplo es un problema convexo, y si su región factible es acotada

$$\begin{array}{ll} \text{mín} & x_1^2 + x_2^2 \\ \text{s.a:} & \frac{x_1}{1 + x_2^2} \leq 0 \\ & (x_1 + x_2)^2 \leq 0 \end{array}$$

Ejercicio (Usar condición de 2^{do} orden para convexidad)


Condiciones de optimalidad general - Caso convexo

Teorema

Considere un problema convexo. Un vector x es óptimo ssi $x \in S$ y

$$(y - x)^T \nabla f(x) \geq 0 \quad \forall y \in S$$

Interpretación



Nota: Si $S = \mathbb{R}^n$ (convexo)

$(y - x)^T \nabla f(x) \geq 0 \quad \forall y \in \mathbb{R}^n$, En particular $y = x - \nabla f(x)$

$$\Rightarrow -\nabla f(x)^T \nabla f(x) \geq 0 \Leftrightarrow -\|\nabla f(x)\|^2 \geq 0$$

$$\Leftrightarrow \nabla f(x) = 0$$

Condición de optimalidad sin restricciones.