

# Modelamiento y Optimización

## Clase 24

Gonzalo Muñoz

14 de Junio 2024



# Recapitulemos

KKT:

$$\begin{array}{ll} \min & f(x) \\ \text{s.a.} & g_i(x) \leq 0 \\ & h_j(x) = 0 \end{array}$$

$$L(x, \lambda, \mu) = f(x) + \sum_{i=1}^m \lambda_i g_i(x) + \sum_{j=1}^p \mu_j h_j(x)$$

$$g_i(x^*) \leq 0 \quad \forall i = 1, \dots, m$$

$$h_j(x^*) = 0 \quad \forall j = 1, \dots, p$$

$$\lambda_i^* \geq 0 \quad \forall i = 1, \dots, m$$

$$\lambda_i^* g_i(x^*) = 0 \quad \forall i = 1, \dots, m$$

$$\nabla f(x^*) + \sum_{j=1}^m \lambda_j^* \nabla g_j(x^*) + \sum_{j=1}^p \mu_j^* \nabla h_j(x^*) = 0$$

## Teorema (Dualidad fuerte)

Si el problema **convexo** y que existe un **punto de Slater** en  $S$ . Entonces se cumple dualidad fuerte y el óptimo cumple KKT.

## Teorema

Si el problema **convexo** y un punto satisface KKT, entonces es óptimo y se cumple dualidad fuerte.



# Demostración

Veamos por qué se tiene el último resultado. Sea  $x^*$  y  $(\lambda^*, \mu^*)$  un par que cumple KKT.

Siempre tenemos que  $x^*$  factible  $(\lambda^*, \mu^*)$  dual factible y dual es maximización

$$f(x^*) \geq p^* \geq d^* \geq d(\lambda^*, \mu^*) = \min_{x \in \mathbb{R}^n} L(x, \lambda^*, \mu^*) = (*)$$

$\hookrightarrow$  dualidad débil

En el caso convexo, el Lagrangiano es convexo, por lo tanto :

$$L(x, \lambda, \mu) = f(x) + \underbrace{\sum_{i=1}^m \lambda_i g_i(x)}_{\text{convexo pues } \lambda \geq 0} + \underbrace{\sum_{j=1}^p \mu_j h_j(x)}_{\text{lineal}}$$

$$\nabla L(x, \lambda^*, \mu^*) = 0 \text{ es}$$

suficiente para tener mínimo global. Y por KKT

$$\nabla L(x^*, \lambda^*, \mu^*) = 0 \Rightarrow x^* \text{ min. del Lagrangiano}$$

$$(*) = L(x^*, \lambda^*, \mu^*) = f(x^*)$$

$\hookrightarrow$  por holgura complementaria.



# Ejemplo

Considere el siguiente problema donde  $c \neq 0$  y  $Q$  es invertible y simétrica:

$$\begin{array}{ll} \text{mín} & c^T x \\ \text{s.a.} & x^T Q x \leq 1 \end{array}$$

1. Plantee las condiciones de KKT.
2. Pruebe que la restricción es activa para un punto que satisface KKT.
3. Encuentre un candidato a óptimo.
4. ¿Bajo que condiciones este candidato es un óptimo global?  
Justifique su respuesta.

$$1.- \quad L(x, \lambda) = c^T x + \lambda (x^T Q x - 1)$$

$$\text{KKT: (1) } x^T Q x - 1 \leq 0$$

$$(2) \quad \lambda \geq 0$$

$$(3) \quad \lambda (x^T Q x - 1) = 0$$

$$[\nabla (x^T Q x) = 2Qx]$$

$$(4) \quad c + 2\lambda Q x = 0$$



# Ejemplo

$$2.- \text{ Si } x^T Q x - 1 < 0 \Rightarrow \lambda = 0 \quad (3)$$

$$\text{en (4)} \Rightarrow C = 0 \rightarrow \text{pues } C \neq 0$$

$$3.- (4) \Rightarrow 2\lambda Q x = -C \Rightarrow Q x = \frac{-C}{2\lambda} \Rightarrow x = \frac{-Q^{-1}C}{2\lambda}$$

↑  
parte anterior,  $\lambda \neq 0$

$$\text{parte anterior} \Rightarrow x^T Q x = 1 \Rightarrow \left( \frac{-Q^{-1}C}{2\lambda} \right)^T Q \left( \frac{-Q^{-1}C}{2\lambda} \right) = 1$$

$$\Rightarrow C^T \underbrace{Q^{-1} Q}_{I} Q^{-1} C = 4\lambda^2$$

$$\Rightarrow \lambda^2 = \frac{C^T Q^{-1} C}{4}$$

$$\Rightarrow \lambda = \frac{1}{2} \sqrt{C^T Q^{-1} C}$$

↑  
 $\lambda \geq 0$

$$\Rightarrow x = \frac{-Q^{-1}C}{2\lambda} = \frac{-Q^{-1}C}{\sqrt{C^T Q^{-1} C}}$$

candidato a  
óptimo.

4.- Si el problema es convexo, es óptimo global.

Cuando  $Q \succeq 0$  (semi-def positiva) el problema es convexo.

# Ejemplo (propuesto)

Considere el problema

$$\begin{aligned} \text{máx} \quad & \prod_{i=1}^n x_i^{a_i} \\ \text{s.a.} \quad & \sum_{i=1}^n x_i = 1 \\ & x \geq 0, \end{aligned}$$

donde  $a_i > 0, \forall i \in \{1, \dots, n\}$ .

1. Muestre que es equivalente resolver el problema  $\text{máx} \sum_{i=1}^n a_i \log(x_i)$ , s.a.  $\sum_{i=1}^n x_i = 1, x \geq 0$ .
2. Escriba las condiciones de KKT del problema de la parte anterior.
3. Encuentre un óptimo global a este problema y muestre que es único.

1.- clave: logaritmo es creciente, y el óptimo no es 0. Así que se puede tomar log del objetivo.

2.- ojo: transformar a minimización y  $x \geq 0 \leadsto -x \leq 0$

3.- Resolver KKT y mostrar que el problema es convexo y cumple Slater.



# Teorema de Karush-Kuhn-Tucker

En el caso **no-convexo** también hay casos donde se satisface KKT:

## Teorema (Karush-Kuhn-Tucker)

Sea  $x^*$  factible e  $I = \{i = 1, \dots, m : g_i(x^*) = 0\}$  el conjunto de restricciones activas en  $x^*$ . Supongamos que

$$\left\{ \nabla g_i(x^*) : i \in I \right\} \cup \left\{ \nabla h_j(x^*) : j = 1, \dots, p \right\}$$

LICQ  
"linear independence  
constraint qualification"


son vectores **linealmente independientes**. Entonces, si  $x^*$  es mínimo local del problema, existen  $\lambda_i \geq 0$ ,  $i = 1, \dots, m$  y  $\mu_i \in \mathbb{R}$ ,  $i = 1, \dots, p$  tales que  $x^*$  y  $(\lambda, \mu)$  satisfacen las condiciones de KKT.



# Ejemplo

Resolver el siguiente problema gráficamente, y verificar que el óptimo satisface las condiciones LICQ.

$$\begin{aligned} \text{mín } & 2x + y \\ \text{s.t. } & x^2 + y^2 \geq 1 \\ & x, y \geq 0 \end{aligned}$$



$$\text{Óptimo } (x, y) = (0, 1)$$

restricciones activas

$$-x^2 - y^2 + 1 \leq 0$$

$$-x \leq 0$$



# Ejemplo

$$\nabla(-x^2 - y^2 + 1) = \begin{pmatrix} -2x \\ -2y \end{pmatrix} \xrightarrow{\text{en } (0,1)} \begin{pmatrix} 0 \\ -2 \end{pmatrix}$$

$$\nabla(-x) = \begin{pmatrix} -1 \\ 0 \end{pmatrix} \rightsquigarrow \begin{pmatrix} -1 \\ 0 \end{pmatrix}$$

vectores ortogonales, en particular l.i.,  
así que se cumple LICQ.

$\Rightarrow$  se cumple KKT

Teorema

# Cuando LICQ no se cumple

La clase pasada vimos que el siguiente problema tiene un óptimo global, pero **no tiene puntos que satisfagan KKT**.

$$\begin{aligned} &\text{mín } x_2 \\ &\text{sujeto a: } (x_1 - 1)^2 + x_2^2 \leq 1 \\ &\quad \quad (x_1 + 1)^2 + x_2^2 \leq 1 \end{aligned}$$

Veamos ahora qué pasa con LICQ.

